

22. Теорема Гаусса-Маркова: выражение $Cov(\tilde{a}, \tilde{a})$ и его обоснование.

$$Cov(\tilde{a}, \tilde{a}) = \tilde{\sigma}_u^2 \cdot (X^T \cdot X)^{-1} = \tilde{\sigma}_u^2 \cdot Q$$

Доказательство:

$\tilde{a} = (X^T P X)^{-1} X^T P \vec{y} = M \cdot \vec{y}$ – оценивание вектора \vec{a} ; \tilde{a} – линейное преобразование \vec{y} .

$$\tilde{a} = A \cdot \vec{y} + \vec{b}, \text{ где } A = M, \vec{b} = \vec{0}$$

Тогда по теореме Фишера

$$\begin{aligned} Cov(\tilde{a}, \tilde{a}) &= M \cdot Cov(\vec{y}, \vec{y}) \cdot M^T = (X^T P X^{-1}) \cdot X^T P \cdot (\sigma_0^2 P^{-1}) X (X^T P X)^{-1} = \\ &= \sigma_0^2 \cdot (X^T \cdot X)^{-1} = \sigma_0^2 \cdot Q \quad \blacksquare \end{aligned}$$

Более подробное доказательство смотри пункт 13

23. Теорема Гаусса-Маркова: предпосылки и свойство наименьших квадратов

$$\tilde{u}^T \cdot \tilde{u} \rightarrow \min.$$

Пусть в уравнениях наблюдений $\vec{y} = X\vec{a} + \vec{u}$:

0. Столбцы X линейно независимы;

$$1. E(u_1) = \dots = E(u_n) = 0;$$

$$2. Var(u_1) = \dots = Var(u_n) = \sigma_u^2; - \text{ не зависят от объясняющих переменных}$$

3. $Cov(u_i, u_j) \neq 0, i \neq j$; - Случайные остатки попарно некоррелированные

4. $Cov(u_i, x_{mj}) = 0$. - Значения объясняющих переменных не коррелированы со значениями случайных возмущений

Тогда выполняются необходимые утверждения (не все, только те, которые требуются в вопросе):

А) $\tilde{a} = (X^T X)^{-1} X^T \vec{y}$ – оптимальная линейная процедура оценивания коэффициентов функции регрессии.

С) Оценки, вычисленные в А, обладают замечательным свойством наименьших

квадратов, то есть $\sum_{i=1}^n \tilde{u}_i^2 \rightarrow \min$. Именно это свойство является причиной

общепринятого названия процедуры А – МНК.

24. Теорема Гаусса-Маркова: выражение $\tilde{\sigma}_0^2$

2-я предпосылка теоремы Гаусса-Маркова о гомоскедастичности случайного остатка не выполнена, то есть дисперсия зависит от объясняющих переменных, а остаток гетероскедастичен. В таком случае оценки параметров модели утрачивают свое свойство оптимальности (свойство минимальных дисперсий). Для построения оптимальной процедуры оценивания модели с гетероскедастичным остатком потребуется модель гетероскедастичности остатка, вот простейший вид такой модели:

$$Var(u) = \sigma_u^2 = \sigma_0^2 \left(\sum_{j=0}^k |x_j| \right)^\lambda$$

σ_0^2 имеет смысл дисперсии такой случайной величины, вес которой равен 1, поэтому называется дисперсией единицы веса.

λ -некоторое априорно заданное число (подбирается экспериментально)

$p = \frac{\sigma_0^2}{\sigma_u^2}$ – вес случайного возмущения

Величина $\tilde{\sigma}_0^2 = \frac{\tilde{u}^T P \cdot \tilde{u}}{n - (k + 1)} = \frac{\sum_{i=1}^n p_i \cdot \tilde{u}_i^2}{n - (k + 1)}$ - несмещенная оценка σ_0^2

25. Взвешенный метод наименьших квадратов (ВМНК). Практическая реализация ВМНК.

В данном случае предпосылка 2 теоремы Гаусса-Маркова нарушается (случайное возмущение гетероскедастично).

Алгоритм взвешенного метода наименьших квадратов (ВМНК) состоит в предварительной трансформации ЛМНР с гетероскедастичным остатком к модели с гомоскедастичным остатком, далее проверке гомоскедастичности остатка в трансформированной модели и, наконец, в применении процедуры МНК.

$\vec{y} = X\vec{a} + \vec{u}$ - уравнения наблюдений

Ковариационная матрица имеет следующий вид:

$$\Omega_{\vec{u}} = \sigma_0^2 P^{-1} = \sigma_0^2 \cdot \begin{pmatrix} \frac{1}{p_1} & 0 & \dots & 0 \\ 0 & \frac{1}{p_2} & \dots & 0 \\ \dots & \dots & \dots & \dots \\ 0 & 0 & \dots & \frac{1}{p_n} \end{pmatrix}$$

Составим уравнения наблюдений:

$$\begin{cases} \sqrt{p} \cdot y = \sqrt{p} \cdot a_0 + \sqrt{p} \cdot a_1 x_1 + \sqrt{p} \cdot a_2 x_2 + \dots + \sqrt{p} \cdot a_k x_k + \sqrt{p} \cdot u \\ E(\sqrt{p} \cdot u) = 0; \quad E((\sqrt{p} \cdot u)^2) = \sigma_0^2 \end{cases}$$

$$\frac{1}{(\vec{y})} P^2 \cdot \vec{y} = P^2 \cdot \underset{(X')}{X} \cdot \vec{a} + \vec{v} \quad (1)$$

$$P^{-\frac{1}{2}} = \begin{pmatrix} \frac{1}{\sqrt{p_1}} & 0 & \dots & 0 \\ 0 & \frac{1}{\sqrt{p_2}} & \dots & 0 \\ \dots & \dots & \dots & \dots \\ 0 & 0 & 0 & \frac{1}{\sqrt{p_n}} \end{pmatrix}$$

(1) удовлетворяют всем предпосылкам теоремы Гаусса-Маркова, следовательно, можем оценить параметры с помощью МНК.

А-Д теоремы Г-М превращаются в следующие утверждения:

$$A) \tilde{\vec{a}} = (X^T \cdot P \cdot X)^{-1} \cdot X^T \cdot P \cdot \vec{y} = Q \cdot X^T \cdot P \cdot \vec{y}$$

$$B) \tilde{\sigma}_0^2 = \frac{\sum_{i=1}^n \tilde{v}_i^2}{n - (k + 1)} = \frac{\sum_{i=1}^n p_i \cdot \tilde{u}_i^2}{n - (k + 1)}; \text{ - оценка дисперсии}$$

$$\tilde{u}_i = y_i - (\tilde{a}_0 + \tilde{a}_1 \cdot x_{1,i} + \dots + \tilde{a}_k \cdot x_{k,i}); \tilde{v}_i = \sqrt{p_i} \cdot \tilde{u}_i$$

$$C) \sum_{i=1}^n \tilde{v}_i^2 = \sum_{i=1}^n p_i \cdot \tilde{u}_i^2 \rightarrow \min$$

$$D) \begin{cases} S\tilde{a}_j = \tilde{\sigma}_0 \cdot \sqrt{q_{j+1, j+1}} \\ j = 0, 1, \dots, k \end{cases}$$

Свойство C) оценок коэффициентов из A) принято называть *взвешанными наименьшими квадратами*, откуда A) - взвешенный метод наименьших квадратов.

26. Обобщённый метод наименьших квадратов (ОМНК).

Приступаем к доказательству утверждений теоремы Гаусса-Маркова. Мы расширим предпосылки с номерами 2 и 3 этой теоремы отказавшись от них и предполагая, что вектор случайных возмущений \vec{u} имеет нулевое математическое ожидание и ковариационную матрицу $Cov(\vec{u}, \vec{u}) = \sigma_0^2 \cdot P^{-1}$.

Докажем утверждение А:

1) Мы будем разыскивать оценку вектора \vec{a} в классе всех линейных функций определённых на векторе значений эндогенной переменной \vec{y} , так что определению подлежит матрица M этого линейного преобразования мы собираемся разыскать M .

$$\tilde{\vec{a}} = M \cdot \vec{y}$$

2) Поиск матрицы M удобно осуществить создавая оптимальную статистическую процедуру оценивания значения y_0 произвольной линейной функцией вектора

коэффициентов модели

$$y_0 = \vec{x}_0^T \cdot \vec{a}$$

3) Процедуру оценивания числа y_0 мы будем отыскивать в классе линейных функций \vec{y} , где \vec{m} – это строка линейных коэффициентов.

$$\tilde{y}_0 = \vec{m}_0 \cdot \vec{y}$$

И будем отыскивать опираясь на два требования оптимальности:

$$\begin{cases} E(\tilde{y}_0) = y_0 = \vec{x}_0^T \cdot \vec{a} \\ Var(\tilde{y}_0) \rightarrow \min \end{cases}$$

Вычислим мат ожидание символа \tilde{y}_0 . Первое требование оптимальности приводит к следующему уравнению относительно искомых коэффициентов \vec{m} :

$$E(\tilde{y}_0) = \vec{m} \cdot X \cdot \vec{a}, \Rightarrow \vec{m}^T \cdot X = \vec{a}^T = \vec{x}_0^T \cdot \vec{a}$$

Теперь найдём дисперсию опираясь на следующее выражение:

$$Cov(\vec{u}, \vec{u}) = \sigma_0^2 \cdot P^{-1}.$$

$$\text{Значит дисперсия: } Var(\tilde{y}_0) = \sigma_0^2 \cdot \vec{m}^T \cdot P^{-1} \cdot \vec{m}$$

Следовательно искомые оценки коэффициентов нужно найти в процессе решения следующей оптимизационной задачи:

$$\begin{cases} \vec{m}^T \cdot P^{-1} \cdot \vec{m} \rightarrow \min \\ X^T \cdot \vec{m} = \vec{x}_0 \end{cases} \quad (5.11')$$

Задачу 5.11' решаем методом Лагранжа:

Шаг 1. Составим функция Лагранжа:

$$L(\vec{m}, l) = \vec{m}^T \cdot P^{-1} \cdot \vec{m} + \vec{l}^T \cdot (\vec{x}_0 - X^T \cdot \vec{m})$$

символом l обозначен множитель Лагранжа.

Шаг 2. Составим необходимые условия экстремума функции Лагранжа:

$$\begin{cases} \frac{\partial L}{\partial \vec{m}} = 2 \cdot P^{-1} \cdot \vec{m} - X \cdot \vec{l} = 0, \\ \frac{\partial L}{\partial l} = \vec{x}_0 - X^T \cdot \vec{m} = 0. \end{cases} \quad (5.14)$$

Шаг 3. Система 5.14 решается аналитически или методом подстановки:

$$\vec{m} = P \cdot X \cdot (X^T \cdot P \cdot X)^{-1} \cdot \vec{x}_0 \quad (5.15)$$

Следовательно, наилучшая оценка рассчитывается по правилу 5.16:

$$\tilde{y}_0 = \vec{m}^T \cdot \vec{y} = \vec{x}_0^T \cdot (X^T \cdot P \cdot X)^{-1} \cdot \vec{y} \quad (5.16)$$

И последнее действие

$$y_0 = \vec{x}_0^T \cdot \vec{a} \Rightarrow \vec{a} = \left((X^T \cdot P \cdot X)^{-1} \cdot X^T \right) (= M) \cdot P \cdot \vec{y} \blacksquare$$

Это и есть ОМНК.

27. Система нормальных уравнений и явный вид её решения при оценивании методом наименьших квадратов (МНК) линейной модели парной регрессии.

Из $\vec{a} = (X^T P X)^{-1} X^T P \vec{y}$ видно, что \vec{a} вычисляется в процессе решения системы из

$k + 1$ линейных алгебраических уравнений с $k + 1$ неизвестными: $(X^T P X) \vec{a} = X^T P \vec{y}$.

Эта система называется системой нормальных уравнений.

В ситуации процедуры МНК, т.е. $P = E$ её подробная запись принимает следующий вид:

$$\begin{cases} n\tilde{a}_0 + [x]\tilde{a}_1 = [y] \\ [x]\tilde{a}_0 + [x^2]\tilde{a}_1 = [xy] \end{cases}$$

$$\text{где } [x] = \sum_{i=1}^n x_i; [y] = \sum_{i=1}^n y_i; [x^2] = \sum_{i=1}^n x_i^2; [xy] = \sum_{i=1}^n x_i y_i$$

Тогда явный вид решения этой системы:

$$\begin{cases} \tilde{a}_1 = \frac{Cov(x, y)}{Var(x)}; \tilde{a}_0 = \bar{y} - \bar{x}\tilde{a}_1 \end{cases}$$

28. Ковариационная матрица оценок коэффициентов линейной модели парной регрессии: явные выражения $Var(\tilde{a}_0)$, $Var(\tilde{a}_1)$, $Cov(\tilde{a}_0, \tilde{a}_1)$.

Линейная модель парной регрессии имеет вид:

$$\begin{cases} y = a_0 + a_1 x + u \\ E(u) = 0, Var(u) = \sigma_u^2 \end{cases}$$

$$Cov\left(\begin{matrix} \tilde{a}_0 \\ \tilde{a}_1 \end{matrix}\right) = \begin{pmatrix} Var(\tilde{a}_0) & Cov(\tilde{a}_0, \tilde{a}_1) \\ Cov(\tilde{a}_0, \tilde{a}_1) & Var(\tilde{a}_1) \end{pmatrix}$$

$$Cov\left(\begin{matrix} \tilde{a}_0 \\ \tilde{a}_1 \end{matrix}\right) = \sigma_u^2 Q = \sigma_u^2 \begin{pmatrix} Q_{11} & Q_{12} \\ Q_{21} & Q_{22} \end{pmatrix}$$

Учитывая, что $R = X^T X = \begin{pmatrix} n & [x] \\ [x] & [x^2] \end{pmatrix}$ - матрица, образованная коэффициентами

и свободными членами системы $\begin{cases} n\tilde{a}_0 + [x]\tilde{a}_1 = [y] \\ [x]\tilde{a}_0 + [x^2]\tilde{a}_1 = [xy] \end{cases}$

Получаем:

$$Var\left(\tilde{a}_0\right) = \sigma^2 Q_{11} = \sigma^2 \left(\frac{1}{n} + \frac{\bar{x}^2}{\sum_{i=1}^n (x_i - \bar{x})^2} \right)$$

$$Var\left(\tilde{a}_1\right) = \sigma^2 Q_{22} = \frac{\sigma^2}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

$$Cov\left(\tilde{a}_0, \tilde{a}_1\right) = \sigma^2 Q_{12} = \sigma^2 Q_{21} = \frac{-\sigma^2 \bar{x}}{\sum_{i=1}^n (x_i - \bar{x})^2}$$